

LLM 기반 엔터티 정규화 및 Hybrid-RAG 를 활용한 기업 지배구조 및 친족 지분 자동 추론 시스템

Design of Automated Shareholder Structure and Family Ownership Inference System
using LLM-based Entity Normalization and Hybrid-RAG

요약 (Abstract)

한국 기업 집단(Chaebol)의 소유 구조는 순환 출자와 친족 중심의 지배력 행사로 인해 고도의 복잡성을 띤다. 공정거래법상 규제 대상인 '특수관계인'의 범위를 식별하는 것은 투명한 지배구조 확립을 위해 필수적이나, 현행 분석 방식은 전자공시시스템(DART)의 반정형 데이터와 외부의 비정형 웹 데이터를 수작업으로 대조해야 하는 한계가 있다. 본 논문에서는 이러한 문제를 해결하기 위해 **테이블 증강 생성(TAG)**과 웹 검색 기반 증강 생성(Web-RAG), 그리고 동적 엔터티 정규화(Dynamic Entity Normalization) 기술을 통합한 하이브리드 추론 시스템을 제안한다. 제안된 시스템은 LLM을 활용하여 기업명의 이명(Alias)을 정규화하고, 파편화된 주주 정보를 하이퍼그래프 형태의 지식으로 통합하여 구체적인 친족 관계(배우자, 직계존비속 등)를 추론한다. 322개 상장 기업을 대상으로 한 실험 결과, 제안 시스템은 기업당 평균 1.96분의 분석 시간을 기록하여 기존 수작업 대비 효율성을 획기적으로 개선하였으며, 복잡한 사명 변경 이력이 있는 기업에 대해서도 강건한(Robust) 추론 성능을 보였다.

1. 서론 (Introduction)

1.1 연구 배경 및 필요성

대한민국의 기업 생태계에서 '재벌(Chaebol)'로 통칭되는 대기업 집단은 국가 경제 성장의 주역임과 동시에 복잡한 소유 지배 구조로 인한 코리아 디스카운트(Korea Discount)의 주요 원인으로 지목되어 왔다. 총수 일가는 적은 지분으로도 계열사 간 순환 출자나 피라미드식 지배 구조를 통해 그룹 전체에 대한 실질적인 지배력을 행사한다. 이에 따라 공정거래위원회와 금융감독원은 '독점규제 및 공정거래에 관한 법률(공정거래법)'에 의거하여 동일인(총수)과 그 특수관계인(친족, 계열사 임원 등)의 주식 소유 현황을 엄격히 공시하도록 의무화하고 있다.

그러나 이러한 공시 자료가 갖는 데이터적 특성은 분석의 효율성을 저해하는 주요 요인으로 작용한다. 현재 금융감독원의 전자공시시스템(DART)은 기업의 사업보고서, 분기보고서 등을 전자문서 형태로 제공하고 있으나, 그 핵심이 되는 "VII. 주주에 관한 사항" 내의 "최대주주 및 특수관계인의 주식소유 현황"은

반정형(Semi-structured) 표 데이터와 비정형 텍스트가 혼재된 형태로 존재한다.4

현행 주주 분석 프로세스는 분석가나 규제 담당자가 DART 시스템에 접속하여 특정 기업의 보고서를 열람하고, 수십 명에 달하는 주주 명단을 일일이 확인한 뒤, 각 인물이 총수와 어떤 관계인지(예: 사촌, 처남, 단순 임원 등)를 외부 검색 엔진(Google, Naver 등)을 통해 수작업으로 검증하는 방식에 의존하고 있다. 이는 다음과 같은 심각한 문제를 야기한다.

1. **확장성(Scalability)의 한계:** 수백 개에 달하는 상장사와 수천 명의 특수관계인을 실시간으로 모니터링하는 것은 물리적으로 불가능하며, 인적 자원의 막대한 투입을 요구한다.
2. **데이터의 파편화 및 모호성:** 공시 자료에는 주주의 성명과 '특수관계인'이라는 법적 지위만 명시될 뿐, 구체적인 혈연관계(예: 장남, 차녀)는 기술되지 않는 경우가 많다. 또한, 기업의 사명 변경(예: 대림산업 → DL, 동부 → DB)이나 대중적 약칭의 사용은 데이터의 연계를 방해한다.
3. **휴먼 에러의 위험:** 수동 검색 및 계산 과정에서 발생하는 오류는 지배구조 평가의 신뢰도를 저하시키며, 이는 투자자의 의사결정과 규제 당국의 감시에 부정적인 영향을 미친다.

1.2 연구의 목적

본 연구는 최신 인공지능 기술인 대규모 언어 모델(LLM)과 검색 증강 생성(RAG: Retrieval-Augmented Generation) 기술을 융합하여, 위에서 제기된 문제점들을 해결하고, 정보의 비대칭성을 해결하고자 자동화된 주주 구조 분석 시스템을 설계하고 구현하는 것을 목적으로 한다.

구체적인 연구 목표는 다음과 같다. 첫째, LLM 기반 엔터티 정규화 모델(Entity Normalization Model)을 개발하여, 공식 법인명과 통상적 명칭, 과거 사명 간의 불일치를 해소하고 검색의 정확도를 높인다. 둘째, Web-RAG(Web Retrieval-Augmented Generation) 기술을 적용하여, DART 공시 자료에 부재한 주주 간의 구체적인 친족 관계 정보를 뉴스 기사, 위키백과 등 외부 웹 데이터로부터 자동으로 수집하고 추론한다. 셋째, TAG(Table-Augmented Generation) 기법을 활용하여, DART 보고서 내의 복잡한 표 구조를 파싱하고, 추출된 관계 정보를 매핑하여 친족 지분율을 자동으로 산출하는 파이프라인을 구축한다.

구체적으로는 1) DART 표 데이터의 구조적 파싱(TAG), 2) 기업 이명(Alias)의 동적 정규화, 3) 웹 검색을 통한 관계 추론(Web-RAG)의 3 단계 파이프라인을 통해 기업 지배구조를 자동으로 시각화하고 분석하는 시스템을 설계 및 구현한다.

이를 통해 본 연구는 기존의 수작업 위주의 분석 프로세스를 획기적으로 개선하고, KCI 급 학술적 가치를 지니는 금융 도메인 특화 NLP 방법론을 제시하고자 한다.

KEJI 평가 시스템

AI 에이전트 기반 자동 평가 관련 연구 조사

주요 기여도 제시 및 실험 결과 요약

논문 구성 요약

2. 관련 연구 (Related Work)

2.1 금융 도메인에서의 엔티티 인식 및 정규화

금융 텍스트 분석에서 엔티티 인식(NER)은 기업명, 인명, 재무 수치 등을 추출하는 핵심 기술이다.² 그러나 금융 문서는 동일한 기업이 '삼성전자', 'SEC', '005930' 등 다양한 표면형(Surface Form)으로 등장하며, 인수합병이나 사명 변경으로 인해 엔티티의 명칭이 동적으로 변화하는 특성을 가진다.³ 기존의 BERT 기반 모델들은 학습 데이터에 포함되지 않은 새로운 사명이나 약칭을 식별하는 데 한계를 보였다. 최근 연구들은 LLM의 문맥 이해 능력을 활용하여 별도의 추가 학습 없이 프롬프트 엔지니어링만으로 엔티티 정규화(Entity Normalization)를 수행하는 방식을 제안하고 있다.³ 본 연구에서는 이를 확장하여, LLM이 웹 검색을 통해 기업의 브랜드명이나 과거 사명을 스스로 학습하고 매핑하는 동적 정규화 방식을 적용한다.

2.2 RAG 및 TAG 기술


RAG는 LLM의 환각(Hallucination) 현상을 억제하기 위해 외부 지식베이스를 검색하여 답변의 근거로 활용하는 기술이다.⁴ 그러나 일반적인 RAG는 텍스트 위주의 검색에 최적화되어 있어, 재무제표나 주주 명부와 같은 표(Table) 데이터의 구조적 정보(행/열 관계)를 손실하는 문제가 있다. 이에 대한 대안으로 테이블 구조를 보존하며 질의응답을 수행하는 Table-Augmented Generation (TAG) 기술이 주목받고 있다.⁶ TAG는 자연어 질의를 SQL이나 Pandas 쿼리로 변환하여 정량 데이터의 정확성을 보장한다. 본 연구는 DART의 표 데이터를 처리하기 위한 TAG 모듈과, 주주 간의 관계(텍스트)를 추론하기 위한 Web-RAG 모듈을 결합한 하이브리드 아키텍처를 채택한다.

Hybrid-RAG / Hyper-RAG 등등 조사 필요

관련 에이전트 기술 조사 필요

3. 제안한 방법 (Proposed Methodology)

본 장에서는 비정형 금융 공시 데이터로부터 기업의 실질적 지배구조를 파악하기 위한 **LLM 기반 엔터티 정규화 및 Hybrid-RAG 분석 시스템**의 아키텍처와 핵심 알고리즘을 제안한다. 제안 시스템은 파이썬(Python) 기반의 모듈로 구현되었으며, 크게 데이터 수집 및 전처리(Data Ingestion & Preprocessing), 동적 엔터티 정규화(Dynamic Entity Normalization), **관계 추론 및 검증(Relation Inference & Verification)**의 3 단계 파이프라인으로 구성된다.



1) 최적의 Prompt 설계 & 데이터셋 수집, 정제 등

2) LLM 기반 아키텍처 - 업데이트 및 그림 수정 필요; 에이전트 추론 기술 (Reasoning), RAG 검색 기술 등 구체적 기술 필요

3.1 전체 시스템 아키텍처 (System Architecture)

시스템 $\mathcal{S}$ 는 기업 집단 $\mathcal{C}$ 에 속한 특정 기업 c_i 에 대하여, 주주 집합 $H = \{h_1, h_2, \dots, h_n\}$ 간의 관계 R 를 식별하고, 이를 시각화된 그래프 G 와 정형화된 데이터셋 D_{out} 으로

반환하는 함수로 정의된다.

전체 파이프라인은 중앙 제어 모듈인 main.py에 의해 오케스트레이션(Orchestration)되며, 다음과 같은 논리적 흐름을 따른다.

1. **Change Detection:** 현재 시점(t)과 과거 시점($t-1$)의 주주 명부를 비교하여 지분 변동이 발생한 '관심 대상 주주(h_{target})'를 선별한다.
2. **Entity Normalization:** 기업명 c_i 의 이명(Alias) 및 통상 엔터티를 LLM을 통해 정규화한다.
3. **Hybrid-RAG Execution:** 표 데이터(Table)와 웹(Web) 검색 결과를 결합하여 h_{target} 의 구체적인 친족 관계를 추론한다.
4. **Constraint Verification:** 가계도 구성의 논리적 오류(예: 중복된 부친 등)를 검증하고 최종 결과를 산출한다.

3.2 테이블 증강 생성(TAG) 기반 데이터 전처리 모듈

금융감독원 DART 시스템의 "주주에 관한 사항"은 HTML 기반의 반정형 표 데이터로 제공된다. get_shareholder_relationship_table.py 모듈은 이를 분석 가능한 형태로 변환하는 역할을 수행한다.⁸

3.2.1 표 데이터 파싱 및 정규화

입력된 HTML 문서 D_{html} 에 대하여 파서(Parser) 함수 P 는 병합된 셀(Merged Cell)을 분해하고, 헤더를 표준화하여 플랫(Flat)한 데이터프레임 T 를 생성한다.

$$T = P(D_{html}) = \{(h_j, r_{raw}, s_j) \mid h_j \in H\}$$

여기서 h_j 는 주주명, r_{raw} 는 공시된 원천 관계(예: '특수관계인'), s_j 는 보유 주식 수를 의미한다. 이 과정에서 텍스트로 기재된 수치 데이터를 정수형(Integer)으로 변환하고, '친족' 여부를 1 차적으로 필터링하는 전처리 함수 f_{filter} 가 적용된다.

3.3 LLM 기반 동적 엔터티 정규화 (Dynamic Entity Normalization)

본 연구의 핵심 기여점인 get_company_info.py 모듈은 기업명이 뉴스 기사나 소셜 미디어 등 외부 데이터 소스에서 다양하게 변형되어 사용되는 문제(Name Disambiguation)를 해결한다.⁸

3.3.1 엔터티 정규화 알고리즘

기업 c_i 에 대하여 검색 정확도(Recall)를 극대화하기 위한 확장 질의 집합 $Q_{\{exp\}}$ 를 생성한다.

Pseudo 코드 전환 필요

Algorithm 1: LLM-driven Name Normalization

Input: Company Name ($C_{official}$)

Output: Normalized Name (C_{norm}), Past Names (C_{past}), Aliases (C_{alias})

1. Search Query Generation:

```
q_search = f"What is the common name or rebranding history of {C_official}?"
```

2. Preliminary Web Search (DuckDuckGo):

```
Context_web = Search(q_search, top_k=3)
```

3. LLM Inference (Prompt Engineering):

```
Prompt = ConstructPrompt( $C_{official}$ , Context_web)
```

```
# Instruction: "Extract popular brand names and past corporate names."
```

```
Response = LLM(Prompt)
```

4. Normalization:

```
{ $C_{norm}$ ,  $C_{past}$ } = ParseJSON(Response)
```

```
Save to 'company_info.csv'
```

이 알고리즘을 통해 'DB 손해보험'은 '동부화재'로, 'BGF 리테일'은 'CU' 또는 '보광'으로 확장되어, 과거 뉴스 데이터와의 연결성(Linkage)을 확보한다.⁸

3.4 Web-RAG 기반 관계 추론 엔진 (Relation Inference Engine)

search_family_relationship.py 모듈은 DART 표 상의 모호한 관계(예: '특수관계인')를 구체적인 혈연관계(예: '장남', '배우자')로 변환하는 추론 엔진이다.⁸

3.4.1 기준 인물 설정 및 질의 확장

가족 관계의 기준점이 되는 인물 P_{anchor} (주로 총수 또는 회장)를 식별한 후, 분석 대상 주주 h_{target} 와의 관계를 묻는 동적 프롬프트를 생성한다. 이때 앞서 도출된 정규화된 기업명 C_{norm} 이 활용된다.

$$q_{\text{rag}} = f_{\text{prompt}}(C_{\text{norm}}, P_{\text{anchor}}, h_{\text{target}})$$

- 예시: "동부화재(C_{norm}) 김준기(P_{anchor}) 회장과 김남호(h_{target})의 가족 관계는?"

3.4.2 LLM 추론 및 분류 (Reasoning Logic)

Web Search를 통해 수집된 문맥 C_{ctx} 를 바탕으로 LLM은 다음의 조건부 확률을 최대화하는 관계 라벨 L 을 예측한다.

$$L = \operatorname{argmax}_{l \in \mathcal{L}} P(l \mid C_{\text{ctx}}, q_{\text{rag}})$$

- $\mathcal{L} = \{\text{Spouse, Child, Sibling, Parent, In-law, Executive, Others}\}$

이 과정에서 LLM에게는 "이미 법적으로 특수관계인임이 확인되었으므로, 구체적인 촌수를 추론하라"는 사전 지식(Prior Knowledge)이 프롬프트로 주입되어 환각(Hallucination)을 억제한다.

3.5 시스템 파이프라인 및 제약 조건 검증 (Main Pipeline & Verification)

main.py는 전체 프로세스를 통합하고 결과의 무결성을 보증한다.⁸

3.5.1 변동 탐지 (Diff-based Analysis)

효율적인 자원 활용을 위해 모든 기업을 매번 분석하지 않고, 지분 변동이 감지된 기업에 대해서만 심층 분석을 수행한다.

$$\Delta(t) = T_{current} - T_{past}$$

만약 $\Delta(t) \neq \emptyset$ (새로운 주주 등장 또는 지분율 변화)인 경우에만 Web-RAG 프로세스를 트리거(Trigger)한다.

3.5.2 논리적 제약 조건 검증 (Constraint Checking)

LLM이 생성한 관계 데이터가 가계도(Family Tree)의 논리적 구조에 부합하는지 검증하는 사후 처리(Post-processing) 단계이다.

- **Uniqueness Constraint:** "아버지" 관계는 유일해야 한다. (복수의 아버지 식별 시 재검증 요청)
- **Reciprocity Constraint:** A 가 B 의 아들이면, B 는 A 의 부모여야 한다.

최종적으로 검증된 데이터는 `datas/family_graph/` 경로에 시각화된 가계도 이미지(.png)와 구조화된 CSV 파일로 저장되어, 분석가가 즉각적으로 활용할 수 있는 형태의 리포트를 제공한다.

4. 실험 결과 (Experiments & Results)

4.1 실험 환경

본 연구의 유효성을 검증하기 위해 KOSPI 및 KOSDAQ 상장사 중 322 개 기업을 무작위 선정하여 실험을 진행하였다. 실험 환경은 Python 3.10, Ollama(Llama-3-Kor-8B), DuckDuckGo Search API 를 기반으로 구축되었다.⁸

데이터셋 분석

제안한 시스템 상에 스텝별 결과 분석

4.2 실험 효율성 평가

- 1) 평균 소요 시간, 정확도 실험 평가 필요
- 2) 다양한 LLM Agent 비교 분석 : Ollama, GPT-OSS 등등

수작업 분석과 제안 시스템의 처리 시간을 비교한 결과는 Table 1 과 같다.

분석 방식	1 개 기업 평균 소요 시간	322 개 기업 총 소요 시간
수작업 (Manual)	45.0 분 (추정)	약 241 시간
제안 시스템 (Proposed)	1.96 분	10 시간 32 분

Table 1. Efficiency Comparison. 제안 시스템은 수작업 대비 약 22 배의 속도 향상을 보였다.⁸

4.3 정성적 분석: BGF 리테일 사례

'BGF 리테일'의 경우, 시스템은 '홍석조(회장)', '홍석현(형)', '홍라영(자매)' 등의 관계를 정확히 식별하였다. 특히 성이 같아 친족으로 오분류되기 쉬운 '홍철기(임원)'에 대해, 뉴스 검색 결과를 바탕으로 "BGF 리테일 상무로 재직 중이며 직계존비속 관계가 아님"을 추론하여 '비친족(Non-Family)'으로 정확히 분류해냈다.⁸ 이는 Web-RAG 가 단순 이름 매칭을 넘어 문맥적 관계를 이해함을 시사한다.

시스템 구현 결과 관점에서 분석

5. 결론 (Conclusion)

본 논문에서는 기업 지배구조 분석의 효율성과 정확성을 높이기 위해 LLM 기반의 엔터티 정규화와 Hybrid-RAG 기술을 통합한 시스템을 제안하였다. 제안된 방법은 DART의 정형 표 데이터와 웹상의 비정형 텍스트 데이터를 유기적으로 결합하여, 기존 수작업 방식의 한계를 극복하고 실시간에 가까운 분석을 가능하게 했다. 향후 연구에서는 지식 그래프(Knowledge Graph)를 도입하여 기업 간의 순환 출자 고리를 시각화하는 Graph-RAG 모델로 확장할 계획이다.

References

- ⁸ shareholder_relationship_table.pdf
- ⁸ get_company_info.pdf
- ⁸ search_family_relationship.pdf
- ⁸ main.pdf
- ⁸ 가족주주판별모델_경실련_11_27.pdf
- ⁷ Table Augmented Generation (TAG)
- ³ LLM based entity normalization financial domain

참고 자료

1. What Determines the Ownership Structure of Business Conglomerates? On the Cash Flow Rights of Korea's Chaebol | ECGI, 1 월 3, 2026 에 액세스, <https://www.ecgi.global/publications/working-papers/what-determines-the->

[ownership-structure-of-business-conglomerates-on](#)

2. kaisugi/entity-related-papers: Named Entity Recognition, Entity Linking, and more – GitHub, 1 월 3, 2026 에 액세스, <https://github.com/kaisugi/entity-related-papers>
3. Financial Named Entity Recognition: How Far Can LLM Go? – ACL Anthology, 1 월 3, 2026 에 액세스, <https://aclanthology.org/2025.finnlp-1.15.pdf>
4. HallucinationFree? Assessing the Reliability of Leading AI Legal Research Tools – Daniel E. Ho – Stanford University, 1 월 3, 2026 에 액세스, https://dho.stanford.edu/wp-content/uploads/Legal_RAG_Hallucinations.pdf
5. Retrieval-augmented generation – Wikipedia, 1 월 3, 2026 에 액세스, https://en.wikipedia.org/wiki/Retrieval-augmented_generation
6. What is Table-Augmented Generation (TAG)? A Practical Guide – K2view, 1 월 3, 2026 에 액세스, <https://www.k2view.com/what-is-table-augmented-generation>
7. Table Augmented Generation: Enhancing LLMs with Structured Data – DEV Community, 1 월 3, 2026 에 액세스, <https://dev.to/foxgem/table-augmented-generation-enhancing-llms-with-structured-data-3kb5>
8. 1_shareholder_relationship_table.pdf